ビズリーチの機械学習基盤

株式会社ビズリーチ システム本部 AI室 機械学習エンジニア 右田 尚人

2019年2月23日 第33回 Machine Learning 15minutes!

- 名前: 右田 尚人(ミギタ ナオト)
- 2015/04~2018/5: 富士通
 - ニューラルネットワーク系の自然言語処理の研究開発
 - AIサービスの導入支援・PoC(FAQ検索など)
- 2018/7~: ビズリーチ
 - レコメンドエンジン開発
 - 機械学習基盤開発



企業と求職者のマッチング、求人の職種・業種・年収**推定**など様々な箇所で機械学習を活用

例: 求人内容から職種・業種を推定

課題

● 様々な求人サイトから収集している ため横断的な職種・業種がない

内容

- 求人情報から自然言語処理で求人の 特徴を抽出
- その特徴を学習して職種業種を推定
- 検索条件やデータ分析などで利用

参考: BizReach Tech Blog

https://tech.bizreach.co.jp/posts/276/gtc2018-japan-report/





①データサイエンティスト・機械学習エンジニアの作業負荷低減

例: 新たなレコメンドエンジンを実装する時



前に作ったバッチ処理と同じ形で作っておいてね deployの手順書はこれを参照してね 既存の動作についてちょっとだけ説明するね。

バッチ処理の動作はDockerのImageとしてBuildされてます。処理を動かす時は、AWSのLambdaをKickしてね。処理が始まると、AutoScalingGroupの設定を変更してスポットインスタンスを払い出して、そのインスタンス上で処理が実施されるよ。実施中の口グはCloudWatchに吐かれていて、もしErrorが発生したら、Slackに通知が飛ぶようになってる。ここまでの設定は、CloudFormationを使うことで適宜定義しているよ。

あ、そうそう、データについては事業部側のS3から取ってくるので専用のRoleを用意して事業部側に権限を付与してもらう必要もあるね。

<u>まあ、これ読めばわかるから、</u> <u>あとよろしく!</u>



①データサイエンティスト・機械学習エンジニアの作業負荷低減

例: 新たなレコメンドエンジンを実装する時

前に作ったバッチ処理と同じ形で作っておいてね deployの手順書はこれを参照してね

インフラ専門じゃない エンジニアに 全部投げるの無理だから

てBuildされ pdaをKickし pupの設定を して、その 実施中の口 irrorが発生

での設定は、CloudFormationを使うことで適宜定義しているよ。

あ、そうそう、データについては事業部側の**S3**から取ってくるので専用の**Role**を用意して事業部側に権限を付与してもらう必要もあるね。

まあ、これ読めばわかるから、

あとよろしく!

なぜ私たちは機械学習基盤を必要としたのか?



②インフラ側の特殊な条件

- 様々な環境に対して基盤を展開する必要アリ
- 事業部側がサービスを管理しているため サービス x (本番|開発)環境ごとにAWS アカウントを発行
- 今後は他クラウドサービス(GCP、Azure)対応の可能性も









BIZREAC肖

まとめ

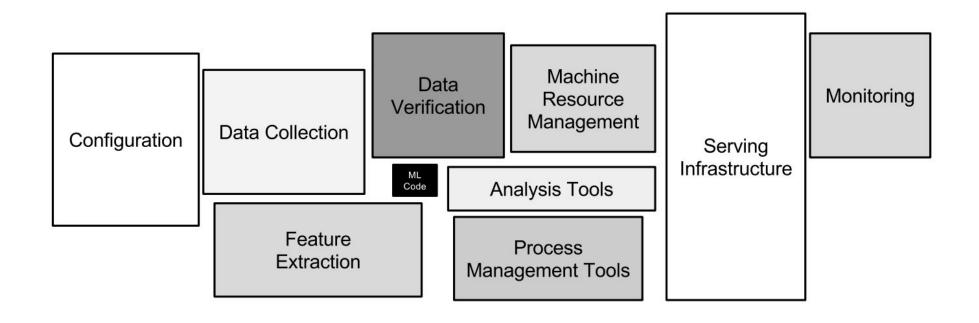
複数の環境に**お手軽に展開**できて、 インフラを**あまり意識しない**で使える基盤が 欲しい

から作りました



機械学習サービスの課題

Hidden Technical Debt in Machine Learning Systems NIPS2015



https://papers.nips.cc/paper/5656-hidden-technical-debt-in-machine-learning-systems.pdf



- KubeFlow
 - ・ KubeCon2017年でgoogleが発表した OSSプロジェクト
 - kubernetes上に機械学習基盤を構築
 - ・ 現状だと発展途上かつGCP依存が多そう (PipelinesはGKE依存)



Kubeflow

KUBEFLOW DOCS

JUPYTERHUB

TFJOB DASHBOARD

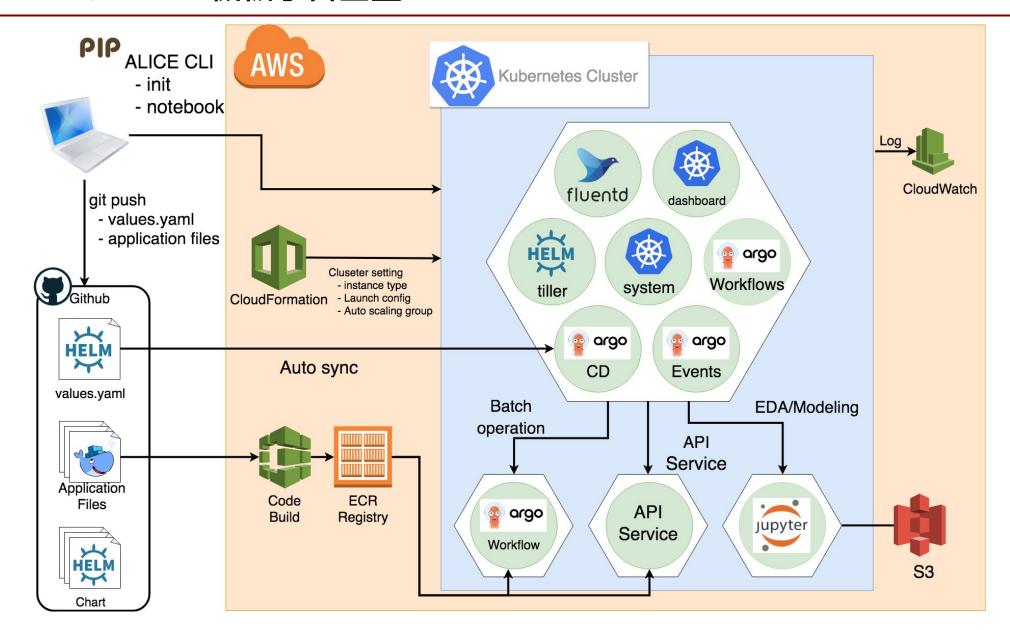
KATIB DASHBOARD

PIPELINE DASHBOARD

https://www.kubeflow.org/docs/other-guides/accessing-uis/

ビズリーチの機械学習基盤 ALICE





values.yaml 概要

```
# Environment settings
# environment. local or aws are available.
# aws settings
aws:
 instanceType: t3.small
  spotPrice: "0.008"
  volumeSize: "8"
argood: false
************************************
# Deployment settings
# deployment environment
# dev, stq, prd
depEnv: dev
# workflow or webhook or calendar
mode: workflow
# only valid for webhook mode
webbook:
 port: "12000"
# only valid for calendar mode
# you must specify "schedule" or "interval" when you use calendar mode.
# "schedule" takes precedence over "interval".
  schedule: "*/30 * * * *
  interval: 30m
# Application settings
# argo workflow
- - name: preprocess
   template: preprocessor
- - name: training
   template: trainer
- - name: prediction
    template: predictor
# container definitions.
containerTemplates:
- name: preprocessor
image: "XXX.ecr.amazonaws.com/sample/preprocessor:latest"
- name: trainer
    image: "XXX.ecr.amazonaws.com/sample/sample/trainer:latest"
    image: "XXX.ecr.amazonaws.com/sample/sample/predictor:latest"
```

worker Nodeのスペック

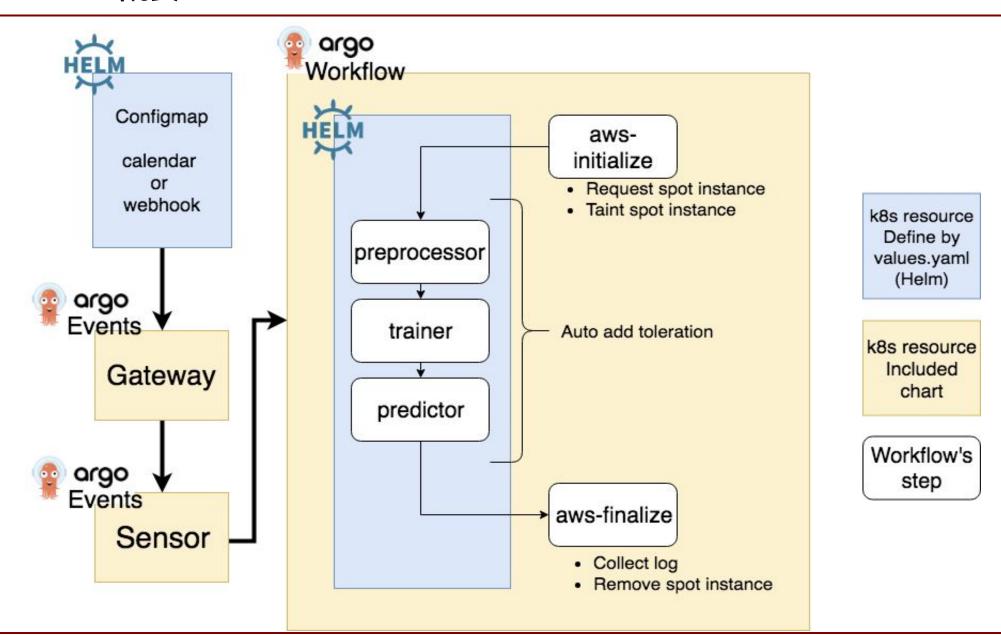
- ボリューム
- インスタンスタイプ
- スポットインスタンスの入札価 など

インフラに依らないデプロイ仕様の設定 (アプリを**どのように動かしたい**か)

- 動作モード: calendar/webhook
- モード固有設定

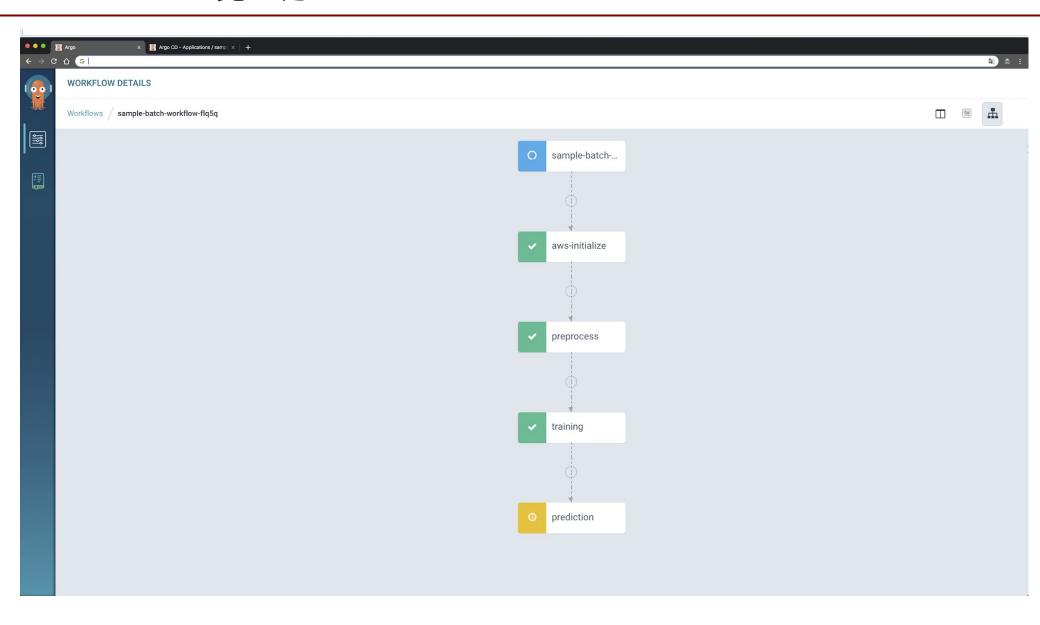
アプリケーション動作設定

- Workflow実行順
- 起動コンテナ定義



Workflowの見え方





複数の環境にお手軽に展開できてインフラをあまり意識しない で使える基盤をkubernetesを使って開発

- ALICE CLIの提供
 - init: kubernetesクラスタをコマンド1つで展開
 - notebook: jupyter notebookをクラスタ上に展開
- アプリDeploy時の設定は、1枚のファイルを書くだけ
 - 最低限のAWS, Argoの知識があればDeploy可能になった
 - ・ 設定ファイルの変更は、Argo CDでAuto sync。GitOpsを実現
- Argoによって柔軟なworkflowを定義可能
 - preprocess、training、predictionなどのジョブごとに コンテナやマシンスペックを選べる

- 脱AWS依存
 - CodeBuild -> skaffold?
 - fluentd + CloudWatch Logs -> Prometheus?
- インフラエンジニアとの連携
 - Kubernetes周りは登場人物も多くてキャッチアップが大変
 - 専門の人に頼りたい
- ALICEを外部公開
 - ・ まずはhelm chartから公開予定

BIZREACĦ